

UNIDAD N° 1

ESTADÍSTICA UNIDIMENSIONAL

EJERCICIO RESUELTO

(A) SITUACIÓN

Imagina que estás trabajando en equipo creando un programa. Cada vez que alguien del equipo hace un cambio en el código, un sistema automático se encarga de probarlo para asegurar que no se haya roto nada.

El equipo notó que últimamente estas pruebas automáticas están tardando demasiado tiempo en terminar. Como hay que esperar a que las pruebas pasen para poder seguir avanzando, esto está retrasando la entrega del proyecto.

Para investigar el problema, decidieron medir cuántos minutos tardaron en ejecutarse las pruebas durante los últimos 12 días de trabajo.

Tiempos registrados (en minutos)

4.2	4.5	3.8	5.0	4.1	18.5	4.3	3.9	4.6	4.0	4.2	4.8
-----	-----	-----	-----	-----	------	-----	-----	-----	-----	-----	-----

(B) CONSIGNAS

1. Identificar la variable medida, clasificarla y plantear una escala de medición para la misma.

2. Cálculo de Medidas de Tendencia Central

Calcular los siguientes indicadores e indica sus unidades:

- **Media aritmética ($\bar{x}$)**
- **Mediana (Me)**
- **Modo (Mo)**

3. Cálculo de Medidas de Dispersión

Determinar qué tan variables son los tiempos de ejecución:

- **Rango (R)**
- **Varianza muestral (s^2)**
- **Desvío estándar (s)**
- **Coeficiente de Variación (CV):** Expresar este resultado en porcentaje.

4. Cálculo de Medidas de Posición

Obtener los siguientes valores para entender la distribución e interpretarlos:

- **Primer Cuartil (Q_1)**
- **Tercer Cuartil (Q_3)**
- **Percentil 90 (P_{90})**

5. Sobre obtenidos los cálculos, responder de forma fundamentada:

- (a) **El efecto del valor atípico (u outlier):** Observar el dato 18.5. *¿Cómo afecta este valor a la relación entre la media y la mediana?* Explicar qué ocurrió técnicamente (sesgo).
- (b) **Representatividad:** Si el Project Manager preguntara: *"¿Cuánto suelen tardar estas pruebas usualmente?"*, *¿qué medida (media o mediana) usarías para no darle una falsa impresión de lentitud?*
- (c) **Criterio de Dispersión:** Si el Coeficiente de Variación supera el **30%**, el proceso se considera "inestable". Según los cálculos pedidos, *¿es este proceso de pruebas estable o requiere una revisión técnica urgente?*
- (d) **Interpretación de Posición:** Si el percentil 90 es el límite aceptable para el cliente, *¿qué porcentaje de las pruebas realizadas quedaron fuera de los estándares de eficiencia?*

Observaciones:

- **La Media falsea:** La presencia de errores en los scripts o eventos de tipo *timeout* (por ejemplo, el valor 18.5) provoca una sobreestimación de la media, reduciendo su capacidad para representar fielmente el comportamiento habitual del proceso observado en la mayoría de los días.
- **La Mediana resiste:** La mediana es una medida de tendencia central robusta que permite describir el patrón de comportamiento que guarda el conjunto de datos, al no verse afectada por los valores atípicos.

- **El Coeficiente de Variación (CV) concluye:** Un mismo desvío absoluto puede tener implicancias muy diferentes según la magnitud del proceso analizado: no es equivalente un desvío de 2 minutos en un proceso de 5 minutos que en uno de 60. El CV permite evaluar esta diferencia al expresar la variabilidad en términos relativos.

(C) RESOLUCIÓN

Aclaración importante: Entender cuándo agrupar o no los datos es clave tanto en el análisis estadístico como cuando se decide cómo guardar información en una base de datos.

En este ejercicio, los tiempos de las pruebas se tratarán como **datos no agrupados** debido al reducido tamaño de la muestra (menor de 30 registros), lo que permite trabajar directamente con los valores originales de cada observación sin pérdida de información. Dado que cada registro aporta información relevante por sí mismo (tiene baja frecuencia), no resulta necesario organizarlos en intervalos o clases para interpretar el comportamiento del proceso.

La agrupación de datos se justifica, en cambio, en contextos con grandes volúmenes de información, donde se prioriza la síntesis y la visualización del patrón general, aun cuando ello implique sacrificar cierto grado de precisión individual.

1. La variable es la *Duración de las pruebas críticas* (medida en minutos).

- **Clasificación:** Se trata de una variable **cuantitativa continua**.
Es una variable cuantitativa, ya que se expresa mediante valores numéricos. Además, es de tipo continua, puesto que el tiempo puede asumir cualquier valor dentro de un intervalo determinado (incluyendo decimales), sin restringirse a valores enteros. Por ejemplo, a diferencia de contar, "cantidad de errores en el código", que es se trata de una variable discreta ya que carece de sentido tener 2.5 errores, pues se tienen 2 o 3 errores.
- **Escala de medición:** Es de **razón** (o proporción). Porque el "0" en esta escala significa ausencia total de la variable que se está midiendo (0 minutos se interpreta como que la prueba no tomó tiempo). Además, esta escala permite realizar comparaciones proporcionales: una prueba con una duración de 8 minutos implica un tiempo de ejecución el doble de una que demora 4 minutos.

2. Cálculo de Medidas de Tendencia Central para datos no agrupados

En primer lugar se ordenarán los datos de menor a mayor ($n = 12$):

3.8; 3.9; 4.0; 4.1; 4.2; 4.2; 4.3; 4.5; 4.6; 4.8; 5.0; 18.5

- **Media aritmética:** Es el resultado de la sumatoria de todos los registros dividida entre el total de datos ($n = 12$). Entonces para el conjunto de datos consignado se tiene:

$$\bar{x} = \frac{\sum_{i=1}^{12} x_i}{12} \cong 5.49 \text{ minutos.}$$

- **Mediana:** Es el valor central del conjunto de datos ordenados. Como se tienen 12 registros (una cantidad par de datos), la mediana se calcula como el promedio de los dos valores centrales. Estos se ubican en la 6.^a y 7.^a posición, cuyos valores son 4.2 y 4.3, respectivamente. Por lo tanto, la **Me = 4.25 minutos**.
- **Modo:** Se trata del valor que aparece con mayor frecuencia en un conjunto de datos. En este caso, el **Mo = 4.2 minutos**.

3. Cálculo de Medidas de Dispersión para datos no agrupados

- **Rango:** Es la diferencia entre el valor máximo y el valor mínimo de un conjunto de datos. Entonces para la situación planteada se tiene:

$$R = (18.5 - 3.8) \text{ minutos} = 14.7 \text{ minutos.}$$

- **Varianza muestral (s^2):** Es la suma de los cuadrados de las diferencias entre cada dato y la media aritmética, dividida entre el tamaño de la muestra menos uno ($n - 1$). En

este caso resulta: $s^2 = \frac{\sum_{i=1}^{12} (x_i - \bar{x})^2}{11} \cong 16.91 \text{ minutos}^2$

- **Desvío Estándar (s):** Es la raíz cuadrada de la varianza muestral.

$$s = \sqrt{16.24 \text{ minutos}^2} \cong 4.11 \text{ minutos}$$

- **Coeficiente de Variación (CV)** Relaciona la desviación estándar con la media aritmética. Generalmente se expresa como porcentaje. Para la situación planteada:

$$CV = \frac{s}{\bar{x}} 100 \rightarrow CV \cong 74.88\%$$

4. Cálculo de Medidas de Posición para datos no agrupados

- El **Primer Cuartil (Q_1)** es la medida estadística de posición que divide un conjunto de datos ordenados de menor a mayor en cuatro partes iguales, representando el valor por debajo del cual se encuentra el 25% de las observaciones inferiores. En este caso, la *primera mitad* (6 datos) la forman los valores: 3.8; 3.9; **4.0; 4.1**; 4.2; 4.2. Como son seis números, se toman los dos del medio y se promedia: $Q_1 = \frac{4.0+4.1}{2} \cong 4.05$ minutos.

Interpretación: El 25% de los días, las pruebas tardaron 4.05 minutos o menos.

- En cuanto al **Tercer Cuartil (Q_3)** se trata de la misma idea comentada para Q_1 pero considerando el 75% de los datos. En este caso se busca la mediana de la segunda mitad. Para los datos de la situación, la *segunda mitad* (6 datos) la componen los valores: 4.3; 4.5; **4.6; 4.8**; 5.0; 18.5. Que al contabilizarse seis números, se toman los dos del medio y se promedia: $Q_3 = \frac{4.6+4.8}{2} \cong 4.70$ minutos.

Interpretación: El 75% de las veces, las pruebas terminaron en 4.7 minutos o menos.

- El **Percentil 90 (P_{90})** expresa el valor por debajo del cual está el 90% de los días considerados. Es una métrica relevante en software (los conocidos "Service Level Agreements" o SLAs con frecuencia se basan en el percentil 90 o 99 para garantizar un buen servicio a casi todos los usuarios).

Para calcularlo, en primer lugar se determina la posición del percentil considerando la cantidad total de datos ($n = 12$). En el caso del percentil 90, la posición se calcula de la siguiente manera:

$$\frac{90}{100} 12 \cong 10.8$$

Este resultado indica que el valor buscado se encuentra entre la 10.^a y la 11.^a posición de los datos ordenados, cuyos valores son 4.8 y 5.0, respectivamente.

$$P_{90} = \frac{4.8 + 5.0}{2} \cong 4.96 \text{ minutos}$$


Interpretación: El 90% de los días, las pruebas tardan menos de 5 minutos en terminar.

4. Respuestas justificadas a cada una de las interrogantes del ejercicio, basadas en los cálculos estadísticos del conjunto de datos dado.

(a) El efecto del valor atípico

El valor atípico de 18.5 minutos incrementa de forma significativa la **media**, llevándola a 5.49 minutos, mientras que la **mediana** permanece prácticamente inalterada, ubicada en 4.25 minutos.

Técnicamente, este único valor atípico introduce un **sesgo positivo** (o asimetría hacia la derecha) en la distribución de los datos.



En una distribución normal o simétrica, la media y la mediana son prácticamente iguales. Sin embargo, cuando existe un sesgo positivo fuerte, la media es "arrastrada" hacia la larga cola de la derecha, perdiendo su capacidad de representar el verdadero centro geométrico de la muestra.

(b) La representatividad para responder al Project Manager

Para no dar una falsa impresión de lentitud, la medida correcta a reportar es la **mediana (4.25 minutos)**.

Justificación: La mediana es lo que en estadística se conoce como una "medida robusta", es decir, es resistente a los valores atípicos. Si le reportas al Project Manager la media (5.49 minutos), le estarás dando a entender que los tiempos de prueba usualmente rondan los cinco minutos y medio. Esto es una falsa impresión porque, en la realidad, 11 de los 12 días laborables registrados tuvieron tiempos de 5.0 minutos o menos. La mediana describe con mucha mayor fidelidad el tiempo de ejecución "típico" del día a día.

(c) Criterio de dispersión (Estabilidad del Proceso)

Al calcular el Coeficiente de Variación se obtuvo $CV \cong 74.88\%$. Si se considera que un alto CV (mayor al 30%) es un indicador de mayor dispersión y menor representatividad de la media. Se puede concluir que como el 74.88% supera ampliamente el umbral del 30%, el proceso de pruebas se clasifica estadísticamente como altamente inestable y, bajo este criterio, requiere una revisión técnica urgente.


(d) Interpretación de posición (Percentil 90)

Si el percentil 90 marca el límite de lo aceptable, exactamente el **10%** de las pruebas quedaron fuera de los estándares de eficiencia.

Justificación: Este resultado se fundamenta en la definición matemática de los percentiles. El percentil 90 corresponde al valor por debajo del cual se concentra el 90% de las observaciones, dejando por encima el 10% restante. En consecuencia, independientemente del valor absoluto que adopte dicho percentil, el 10% de los registros con mayores tiempos de ejecución se considera fuera de los estándares establecidos.

En la muestra analizada de 12 días, este porcentaje equivale aproximadamente a 1.2 observaciones, lo que identifica directamente al registro correspondiente al día con una duración de 18.5 minutos.

Para complementar el análisis anterior, la visualización gráfica es un recurso fundamental. El **diagrama de caja y bigotes** (o *boxplot*) permite corroborar de manera visual aquello que se ha calculado matemáticamente, facilitando la identificación clara de cualquier valor atípico (o *outlier*).



La **caja azul** : Da cuenta sobre dónde se concentran la mayoría de los tiempos de ejecución de las pruebas (entre 4.05 y 4.70 minutos). El **segmento negro** interior de la caja representa la mediana (4.25 minutos). La presencia de los bigotes (en forma de T) cortos significan que los datos no se extienden mucho desde el 50% central

El **punto rojo**: Es el valor atípico dentro de los datos (18.5 minutos). El gráfico lo separa automáticamente de la caja porque no se considera parte del comportamiento "usual" del sistema.

Este gráfico se podría incluir en un informe final para dar cuenta sobre como el sistema funciona bien el 90% del tiempo como así también evidenciar la necesidad de investigar ese incidente aislado.