UNIDAD N° 4

INFERENCIA ESTADÍSTICA

Fundamentos de la Inferencia Estadística

Población, muestra, parámetros, estimadores y estimación puntual

Unidad 4: Fundamentos de la Inferencia Estadística

Población, muestra, parámetros, estimadores y estimación puntual

La inferencia estadística permite tomar decisiones cuando no se dispone de todos los datos. En programación, desarrollo de software, bases de datos y ciencia de datos, esta situación es habitual: una aplicación puede tener miles de usuarios, una API puede recibir millones de peticiones y una base de datos puede contener una cantidad enorme de registros. Analizar todo puede ser costoso, lento o directamente imposible. Por eso se trabaja con una parte de la información y, a partir de ella, se realizan estimaciones sobre el conjunto completo.

La idea central es simple: **observar una muestra para estimar características de una población**. Sin embargo, esa idea requiere precisión conceptual. No alcanza con calcular promedios o porcentajes; también hay que saber qué representan, de dónde provienen los datos, qué parámetro se desea estimar y qué limitaciones tiene la estimación obtenida.

1. De la estadística descriptiva a la inferencia estadística

La estadística descriptiva resume datos observados. Permite calcular medidas, construir tablas, elaborar gráficos y describir el comportamiento de un conjunto de datos disponible. Si se registran 100 tiempos de respuesta de una API y se calcula su promedio, se está describiendo lo que ocurrió en esas 100 mediciones.

La inferencia estadística da un paso más: usa esos datos observados para decir algo razonable sobre un conjunto más amplio. Si esas 100 mediciones se consideran representativas de todas las peticiones que recibe la API, el promedio calculado puede utilizarse como una estimación del tiempo promedio general del servicio.

Estadística descriptiva	Inferencia estadística
Describe datos observados.	Estima características de una población.
Trabaja con datos disponibles.	Trabaja con muestras.
Calcula medias, porcentajes y gráficos.	Usa esos cálculos como estimadores.
No generaliza necesariamente.	Generaliza bajo incertidumbre.
Responde: ¿qué muestran estos datos?	Responde: ¿qué puedo concluir sobre el conjunto total?

La inferencia no elimina la incertidumbre. Su aporte es organizarla, hacerla explícita y reducir el riesgo de tomar decisiones basadas solo en impresiones. En la práctica profesional, esta capacidad es clave para interpretar métricas de rendimiento, analizar errores, validar cambios de software o estudiar preferencias de usuarios.

2. Población: el conjunto sobre el que se quiere concluir

En estadística, la **población** es el conjunto total de elementos que se desea estudiar. No siempre está formada por personas; también puede estar compuesta por registros, transacciones, sesiones, peticiones, tiempos de ejecución, dispositivos, productos o eventos.

En una aplicación web, la población podría ser el conjunto de todas las sesiones de usuario durante un mes. En una base de datos, podría ser el conjunto de todos los registros almacenados. En una prueba de rendimiento, podría ser el conjunto de todas las peticiones que la API podría recibir bajo determinadas condiciones. Lo importante es que la población debe definirse de manera clara, porque de esa definición depende el alcance de las conclusiones.

Una población puede ser **finita** cuando sus elementos pueden contarse. Por ejemplo, los 20.000 usuarios registrados actualmente en una plataforma. También puede ser **conceptual o potencialmente infinita**, como todas las futuras peticiones que recibirá un servidor. En software, esta segunda situación es frecuente porque muchas veces interesa estimar comportamientos futuros o posibles, no solo datos ya existentes.

Cuando se desea conocer una característica de la población, se habla de un **parámetro poblacional**. Por ejemplo, si se quiere conocer el tiempo promedio real de respuesta de una API, el parámetro de interés es la media poblacional de esos tiempos. Como generalmente no se observa toda la población, ese parámetro suele ser desconocido.

3. Muestra: la parte observada de la población

La **muestra** es el subconjunto de la población que efectivamente se observa y analiza. La muestra proporciona los datos concretos con los que se realizan los cálculos. A partir de ella se busca estimar una característica de la población.

Por ejemplo, si la población son todas las peticiones que recibe una API durante una semana, una muestra podría estar formada por 500 peticiones seleccionadas para medir su tiempo de respuesta. Si la población son todos los usuarios de una aplicación, una muestra podría ser un grupo de 300 usuarios encuestados sobre una nueva interfaz.

La muestra debe ser adecuada para el objetivo del análisis. No se trata solo de tomar muchos datos, sino de seleccionar datos que representen razonablemente a la población. Una muestra grande pero sesgada puede llevar a conclusiones incorrectas. Por ejemplo, si se quiere estimar el tiempo promedio de carga de un sitio y solo se miden usuarios con conexión de fibra óptica, la estimación probablemente será demasiado optimista.

Para ordenar el análisis conviene distinguir tres elementos:

Elemento	Pregunta que responde	Ejemplo en una API
Población	¿Sobre quiénes quiero concluir?	Todas las peticiones de la API.
Unidad de análisis	¿Qué observo individualmente?	Cada petición.
Variable de interés	¿Qué característica mido?	Tiempo de respuesta en milisegundos.

Definir estos elementos evita errores frecuentes. No es lo mismo estudiar usuarios que sesiones, sesiones que clics, o registros que campos dentro de registros. Cada decisión modifica la población, la muestra y el tipo de estimador que corresponde usar.

4. Representatividad: condición básica para inferir

Una muestra es **representativa** cuando refleja de manera razonable las características relevantes de la población. La representatividad es fundamental porque la inferencia se apoya en la relación entre muestra y población. Si esa relación está distorsionada, los cálculos pueden ser correctos desde el punto de vista matemático, pero las conclusiones serán equivocadas.

Supongamos que se quiere estimar la proporción de usuarios que prefieren modo oscuro. Si la encuesta se publica solo en un foro de usuarios avanzados, es probable que la muestra no represente a todos los usuarios. Los usuarios avanzados pueden tener preferencias distintas a quienes usan la aplicación ocasionalmente. En ese caso, la proporción obtenida en la muestra no debería generalizarse sin cuidado.

En entornos tecnológicos existen sesgos habituales. Los logs suelen registrar mejor a los usuarios activos que a los inactivos. Las encuestas voluntarias tienden a atraer opiniones extremas. Las pruebas beta suelen incluir usuarios más tolerantes a errores que el público general. Los datos recolectados mediante cookies pueden excluir a quienes no aceptan seguimiento. Cada uno de estos casos puede afectar la representatividad.

La inferencia estadística requiere entonces una actitud crítica: antes de calcular, hay que preguntar **cómo se obtuvieron los datos**. Una muestra pequeña pero bien seleccionada puede ser más útil que una muestra enorme pero sesgada.

5. Parámetros poblacionales

Un **parámetro** es una medida numérica que describe una característica de la población. Como pertenece a la población completa, muchas veces es desconocido. La inferencia estadística intenta aproximarlo mediante información muestral.

La media poblacional se representa con la letra griega μ y expresa el promedio real de todos los valores de la población. Si la población tiene N elementos, se define como:

$$\mu = \frac{1}{N}\sum_{i=1}^{N} x_i$$

Esta fórmula indica que se suman todos los valores poblacionales y se divide por el total de elementos. En el caso de una API, x_i podría representar el tiempo de respuesta de la petición i. Si pudiéramos medir absolutamente todas las peticiones relevantes, obtendríamos μ. En la práctica, ese valor suele estimarse.

La varianza poblacional mide la dispersión real de los valores respecto de la media poblacional:

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2$$

La desviación estándar poblacional es la raíz cuadrada de la varianza:

$$\sigma = \sqrt{\sigma^2}$$

Estas medidas importan porque dos sistemas pueden tener el mismo tiempo promedio de respuesta, pero distinta estabilidad. Un sistema con baja variabilidad responde de forma más predecible; uno con alta variabilidad puede alternar respuestas rápidas con demoras importantes.

Cuando la característica de interés es dicotómica, se trabaja con una proporción poblacional. Por ejemplo, usuario que prefiere modo oscuro / usuario que no lo prefiere; registro con error / registro sin error; sesión que convierte / sesión que no convierte. La proporción poblacional se expresa como:

$$p = \frac{X}{N}$$

donde X es la cantidad de elementos de la población que presentan la característica y N es el tamaño poblacional.

6. Estadísticos muestrales

Un **estadístico** es una medida calculada con los datos de una muestra. A diferencia del parámetro, el estadístico sí se conoce porque se obtiene de datos observados. En inferencia, los estadísticos funcionan como aproximaciones de los parámetros poblacionales.

La media muestral se representa como $\overline{x}$ y se calcula así:

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

También puede escribirse como:

$$\overline{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

donde n es el tamaño de la muestra. Si se miden 5 tiempos de respuesta: 110, 120, 115, 130 y 125 milisegundos, la media muestral es:

$$\overline{x} = \frac{110 + 120 + 115 + 130 + 125}{5} = \frac{600}{5} = 120 \text{ ms}$$

Ese valor resume la muestra y se usa como estimación de μ.

La varianza muestral se representa como s^2:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2$$

Se divide por $n - 1$ porque la media muestral $\overline{x}$ ya fue calculada con los mismos datos. Esta corrección permite que s^2 funcione mejor como estimador de la varianza poblacional. La desviación estándar muestral es:

$$s = \sqrt{s^2}$$

Para proporciones, el estadístico principal es la proporción muestral $\hat{p}$:

$$\hat{p} = \frac{x}{n}$$

donde x es la cantidad de casos favorables observados y n el tamaño de la muestra. Si 136 de 200 usuarios prefieren modo oscuro:

$$\hat{p} = \frac{136}{200} = 0{,}68 = 68\%$$

7. Parámetro, estadístico y estimador: diferencias necesarias

Una confusión frecuente consiste en usar como sinónimos parámetro, estadístico y estimador. Aunque están relacionados, no significan lo mismo.

El **parámetro** es la cantidad poblacional que se quiere conocer. El **estadístico** es una cantidad calculada en la muestra. El **estimador** es la regla o procedimiento que indica cómo usar los datos muestrales para aproximar el parámetro.

Si se quiere estimar…	Parámetro poblacional	Estimador muestral	Estimación obtenida
Una media	μ	$\overline{x}$	Valor de $\overline{x}$.
Una proporción	p	$\hat{p}$	Valor de $\hat{p}$.
Una varianza	σ^2	s^2	Valor de s^2.
Una desviación estándar	σ	s	Valor de s.

Desde una mirada cercana a la programación, un estimador puede pensarse como una función. Recibe datos muestrales como entrada y devuelve un valor numérico como salida:

$$\hat{\theta} = T(X_1, X_2, \ldots, X_n)$$

En esta expresión, θ representa el parámetro poblacional y $\hat{\theta}$ representa su estimador. La letra T indica una regla de cálculo aplicada a la muestra. Por ejemplo, si $\theta = \mu$, una regla natural es calcular $\overline{x}$.

La diferencia entre estimador y estimación también es importante. El estimador es la fórmula general; la estimación es el resultado obtenido con una muestra específica. La fórmula $\overline{x}$ es un estimador. El valor $\overline{x} = 120$ ms es una estimación puntual concreta.

8. Estimación puntual

La **estimación puntual** consiste en usar un único valor muestral para aproximar un parámetro poblacional. Se llama puntual porque el resultado es un punto, es decir, un número único.

Si una muestra de tiempos de respuesta produce $\overline{x} = 120$ ms, se usa ese valor como estimación puntual de μ. Si una muestra de usuarios produce $\hat{p} = 0{,}68$, se usa ese valor como estimación puntual de p.

De manera general:

$$\text{Estimación puntual de } \theta = \hat{\theta}$$

El símbolo $\hat{\theta}$ representa el valor obtenido al aplicar el estimador a una muestra concreta. Si se tomara otra muestra, la estimación podría cambiar. Esa variación no significa que el método esté mal; forma parte del trabajo con muestras.

La estimación puntual es útil porque es simple, clara y fácil de comunicar. Sin embargo, debe interpretarse como una aproximación, no como una certeza absoluta. Decir “el tiempo promedio estimado es 120 ms” no significa afirmar que el promedio real de todas las peticiones sea exactamente 120 ms. Significa que, con los datos disponibles, ese es el mejor valor puntual obtenido.

Aunque el estudio de intervalos de confianza corresponde a una etapa posterior, es importante anticipar una idea: toda estimación puntual tiene error de muestreo. La diferencia conceptual entre estimación y parámetro puede expresarse así:

$$\text{Error de estimación} = \hat{\theta} - \theta$$

En la práctica, θ no se conoce, por lo que ese error exacto no puede calcularse. Por eso más adelante se estudian medidas de incertidumbre como el error estándar. Para la media y la proporción, las formas más habituales son:

$$\mathrm{SE}(\overline{x}) = \frac{s}{\sqrt{n}}$$

$$\mathrm{SE}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Estas expresiones muestran que, en general, muestras más grandes producen estimaciones más estables. Aun así, aumentar n no corrige una muestra mal seleccionada.

9. Procedimiento para realizar una estimación puntual

La estimación puntual no debería comenzar con una fórmula, sino con una definición clara del problema. Un procedimiento ordenado ayuda a evitar errores conceptuales.

Primero se define la población. Por ejemplo: todas las peticiones que recibe una API durante una semana. Luego se identifica la unidad de análisis: cada petición. Después se determina la variable de interés: tiempo de respuesta en milisegundos. A partir de allí se reconoce el parámetro: la media poblacional μ del tiempo de respuesta. Recién entonces se selecciona una muestra y se calcula el estimador correspondiente.

El procedimiento puede resumirse así:

Paso	Pregunta orientadora	Ejemplo
1	¿Cuál es la población?	Todas las peticiones de la API.
2	¿Cuál es la variable?	Tiempo de respuesta.
3	¿Qué parámetro interesa?	Media poblacional μ.
4	¿Qué muestra se observa?	300 peticiones medidas.
5	¿Qué estimador corresponde?	Media muestral $\overline{x}$.
6	¿Qué valor se obtuvo?	$\overline{x} = 118$ ms.
7	¿Cómo se interpreta?	El promedio poblacional se estima en 118 ms.

Este orden es especialmente importante en programación, porque los datos pueden estar disponibles antes de que el problema esté bien formulado. Tener muchos datos no

garantiza un buen análisis. La calidad de la inferencia depende de la coherencia entre pregunta, población, muestra, variable y estimador.

10. Ejemplos integradores aplicados a programación

Ejemplo 1: tiempo promedio de respuesta de una API

Un equipo técnico desea estimar el tiempo promedio de respuesta de una API. La población está formada por todas las peticiones que recibe el servicio en condiciones normales de uso. La variable de interés es el tiempo de respuesta en milisegundos. El parámetro que se desea estimar es μ.

Se toma una muestra de 5 peticiones con los siguientes tiempos:

$$110,\ 120,\ 115,\ 130,\ 125$$

El estimador correspondiente es la media muestral:

$$\overline{x} = \frac{110 + 120 + 115 + 130 + 125}{5} = 120 \text{ ms}$$

La estimación puntual indica que el tiempo promedio poblacional de respuesta se aproxima a 120 ms. La interpretación correcta no es “todas las peticiones tardan 120 ms”, sino “a partir de la muestra observada, se estima que el promedio general está alrededor de 120 ms”.

Ejemplo 2: proporción de usuarios que prefieren modo oscuro

Un equipo de producto quiere estimar la proporción de usuarios que prefieren modo oscuro. La población son todos los usuarios de la aplicación. La variable de interés es la preferencia del usuario, que puede registrarse como “prefiere modo oscuro” o “no prefiere modo oscuro”. El parámetro es p.

Se encuesta a 200 usuarios y 136 responden que prefieren modo oscuro. El estimador es la proporción muestral:

$$\hat{p} = \frac{136}{200} = 0{,}68$$

La estimación puntual es 0,68, equivalente al 68 %. Esto permite afirmar que, según la muestra, se estima que aproximadamente el 68 % de los usuarios prefiere modo oscuro. La calidad de esta conclusión depende de que la muestra represente adecuadamente a los usuarios de la aplicación.

Ejemplo 3: proporción de registros con errores

Un analista necesita estimar qué proporción de registros de una base de datos contiene errores. La población son todos los registros. La variable de interés es la presencia o ausencia de error. El parámetro es p.

Se revisan 500 registros y se encuentran 35 con errores:

$$\hat{p} = \frac{35}{500} = 0{,}07 = 7\%$$

La estimación puntual indica que aproximadamente el 7 % de los registros podría contener errores. Esta información puede servir para decidir si es necesario auditar la base completa, mejorar validaciones o revisar procesos de carga de datos.

11. Errores frecuentes de interpretación

El primer error frecuente es confundir muestra con población. Los datos observados pertenecen a la muestra; la población es el conjunto sobre el cual se desea concluir. Una media muestral no es automáticamente la media poblacional, sino una aproximación.

El segundo error es confundir parámetro con estimador. μ y p pertenecen a la población; $\overline{x}$ y $\hat{p}$ se calculan con la muestra. Esta diferencia debe mantenerse clara para interpretar correctamente los resultados.

El tercer error es pensar que una estimación puntual es exacta. Toda estimación basada en una muestra puede variar si se selecciona otra muestra. Por eso debe comunicarse como aproximación: “se estima que…”, “a partir de la muestra…”, “el valor observado sugiere…”.

El cuarto error es confiar en muestras no representativas. Si los datos provienen solo de usuarios activos, beta testers, conexiones rápidas o encuestas voluntarias, puede haber sesgo. En esos casos, el problema no está en la fórmula, sino en el diseño de la muestra.

12. Síntesis conceptual

La inferencia estadística permite transformar datos muestrales en información útil sobre una población. En esta primera aproximación, los conceptos esenciales son población, muestra, parámetro, estadístico, estimador y estimación puntual.

La lógica general puede expresarse así:

$$\text{Población} \rightarrow \text{Parámetro desconocido} \rightarrow \theta$$

$$\text{Muestra} \rightarrow \text{Estadístico calculado} \rightarrow \hat{\theta}$$

$$\hat{\theta} \approx \theta$$

En palabras: se parte de una población que posee un parámetro desconocido; se observa una muestra; se calcula un estadístico; y ese estadístico se usa como estimador del parámetro.

Para un técnico universitario en programación, esta forma de razonamiento es fundamental. Permite analizar métricas de sistemas, interpretar resultados de pruebas, estimar errores en bases de datos y tomar decisiones basadas en evidencia. La estimación puntual es el primer paso: brinda un valor de referencia. Más adelante, ese valor se complementará con herramientas para cuantificar la incertidumbre, como intervalos de confianza y pruebas de hipótesis.

Autor del material: Prof. Cristian Mut

Bibliografía

- Devore, J. L. (2009). Probabilidad y estadística para ingeniería y ciencias (7.ª ed.). Cengage Learning.
- Triola, M. F. (2018). Estadística (12.ª ed.). Pearson Educación.
- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.