UTN
UNIVERSIDAD TECNOLÓGICA NACIONAL

UNIDAD N° 4

INFERENCIA ESTADÍSTICA

Distribuciones de Muestreo y Teorema del Límite Central

Distribuciones de Muestreo y Teorema del Límite Central

Este material desarrolla el puente matemático que permite pasar de una muestra concreta a conclusiones sobre una población. En la inferencia estadística no alcanza con calcular una media o una proporción: es necesario comprender cómo se comportan esos estadísticos cuando se repite el proceso de muestreo. Ese comportamiento se estudia mediante las **distribuciones de muestreo**, el **error estándar** y el **Teorema del Límite Central**.

En términos operativos, estos conceptos permiten responder preguntas como: qué tan variable puede ser una media muestral, cuándo una muestra es suficientemente grande, cómo calcular probabilidades asociadas a medias de muestras y por qué la distribución normal aparece con tanta frecuencia en problemas de auditoría, control de procesos y análisis de métricas.

1. Por qué se trabaja con muestras

Cuando se desea estudiar una población, la primera idea podría ser medir a todos sus integrantes. Ese procedimiento se denomina **censo**. Sin embargo, en la mayoría de las situaciones reales el censo no es viable. Por eso se selecciona una **muestra**, es decir, una parte de la población que se observa para obtener información útil sobre el conjunto total.

El muestreo se justifica por varias razones. La primera es el **tiempo**: establecer contacto con todos los elementos de una población puede requerir meses o años. Una encuesta electoral completa, por ejemplo, demandaría un tiempo incompatible con la necesidad de publicar resultados antes de una elección. La segunda razón es el **costo**: estudiar a toda una población puede ser económicamente prohibitivo. En el caso de encuestas de hogares, control de calidad o estudios de mercado, una muestra bien diseñada permite obtener resultados adecuados con una fracción mínima del costo total.

También existen situaciones de **imposibilidad física**. Algunas poblaciones son infinitas, se modifican constantemente o no pueden enumerarse por completo. En otros casos, el procedimiento de medición destruye el elemento analizado. Si se prueba la resistencia de todos los cables de acero hasta romperlos, no queda producción útil para vender. Del mismo modo, si se catara toda una cosecha de vino, no quedaría vino disponible para comercializar.

La idea central es que una muestra no se utiliza porque sea perfecta, sino porque permite obtener una aproximación suficientemente buena cuando el estudio completo de la población resulta imposible, lento o demasiado costoso.

Idea clave. El muestreo no elimina la incertidumbre, pero permite trabajar con ella de manera controlada. Para que la inferencia sea válida, la muestra debe seleccionarse con un procedimiento probabilístico y sin sesgo.

2. Muestreo probabilístico y muestras sin sesgo

Una muestra es **probabilística** cuando cada posible elemento de la población tiene una probabilidad conocida de ser seleccionado. Esta característica es fundamental porque permite estudiar matemáticamente el error de muestreo y construir inferencias válidas.

La condición de probabilidad conocida no significa que todos los métodos seleccionen elementos de la misma manera. Existen distintos diseños de muestreo probabilístico, cada uno adecuado para contextos diferentes. Los cuatro métodos centrales son el muestreo aleatorio simple, el muestreo sistemático, el muestreo estratificado y el muestreo por conglomerados.

2.1. Muestreo aleatorio simple

En el **muestreo aleatorio simple**, cada elemento de la población tiene la misma probabilidad de ser incluido en la muestra. Es el método más directo desde el punto de vista conceptual, porque se basa en seleccionar al azar elementos individuales.

Por ejemplo, si una empresa tiene 845 empleados y se desea elegir una muestra de 52, se puede asignar un número de identificación a cada empleado y luego utilizar una tabla de números aleatorios o un generador computacional. Si el primer número válido obtenido fuera 037, entonces el empleado identificado con ese número sería el primero seleccionado.

Este método es útil cuando se dispone de una lista completa de la población. Su principal ventaja es la simplicidad; su principal limitación es que, en poblaciones muy grandes o dispersas, construir esa lista completa puede resultar difícil.

2.2. Muestreo aleatorio sistemático

En el **muestreo sistemático**, se selecciona un punto de inicio aleatorio y luego se elige cada k-ésimo elemento de la población. El intervalo de selección se calcula como:

$$k = \frac{N}{n}$$

donde **N** es el tamaño de la población, **n** es el tamaño de la muestra y **k** es el intervalo de muestreo.

Si una empresa posee 2000 recibos de ventas y necesita revisar una muestra de 100, entonces:

$$k = \frac{2000}{100} = 20$$

Esto significa que se seleccionará cada vigésimo recibo. Si el número inicial elegido al azar es 18, la muestra incluirá los recibos 18, 38, 58, 78 y así sucesivamente.

El muestreo sistemático es rápido y fácil de aplicar. Sin embargo, no debe utilizarse si el orden físico de la población está relacionado con la característica que se desea estudiar. Si existiera un patrón periódico en la lista, la muestra podría quedar sesgada.

2.3. Muestreo aleatorio estratificado

En el **muestreo estratificado**, la población se divide en subgrupos llamados **estratos**. Luego se selecciona una muestra aleatoria dentro de cada estrato. Este método se utiliza cuando se sabe que la población contiene grupos con características diferentes y se quiere garantizar que todos estén representados.

Un ejemplo del material base muestra una población de 352 empresas clasificadas según su nivel de recuperación. La muestra total es de 50 empresas y se distribuye entre los estratos de manera proporcional.

Distribución proporcional del ejemplo:

- Estrato 1: recuperación de 30% y más; 8 empresas; frecuencia relativa 0,02; muestra asignada 1.
- Estrato 2: recuperación de 20% a 30%; 35 empresas; frecuencia relativa 0,10; muestra asignada 5.

- Estrato 3: recuperación de 10% a 20%; 189 empresas; frecuencia relativa 0,54; muestra asignada 27.
- Estrato 4: recuperación de 0% a 10%; 115 empresas; frecuencia relativa 0,33; muestra asignada 16.
- Estrato 5: déficit; 5 empresas; frecuencia relativa 0,01; muestra asignada 1.
- Total: 352 empresas; muestra total 50.

El valor didáctico de este método es que evita que los grupos pequeños queden excluidos por azar. En el ejemplo, incluso el estrato con déficit queda representado en la muestra.

2.4. Muestreo por conglomerados

En el **muestreo por conglomerados**, la población se divide en grupos naturales llamados conglomerados. Estos conglomerados pueden ser regiones, sucursales, unidades geográficas o agrupamientos ya existentes. Luego se seleccionan algunos conglomerados al azar y se estudian elementos dentro de ellos.

Por ejemplo, si una población se divide en 12 regiones y se seleccionan al azar las regiones 2, 7, 4 y 12, los datos se recolectan dentro de esas regiones seleccionadas. La ventaja central es que reduce costos cuando la población está geográficamente dispersa. Su desventaja es que puede ser menos preciso si los conglomerados son muy distintos entre sí.

3. De las muestras a las distribuciones de muestreo

Cada vez que se extrae una muestra de una población, se pueden calcular estadísticos: media muestral, proporción muestral, varianza muestral, entre otros. Una única muestra produce un único valor del estadístico. Sin embargo, si se extrajeran muchas muestras del mismo tamaño, cada muestra podría producir una media diferente.

La **distribución muestral de la media** es la distribución de probabilidad de todas las posibles medias muestrales de tamaño **n** tomadas de una población. No se refiere a la distribución de los datos originales, sino a la distribución de los valores de $\overline{X}$ que se obtendrían al repetir el proceso de muestreo.

En forma conceptual:

$$\text{Población} \rightarrow \text{muchas muestras de tamaño } n \rightarrow \text{muchas medias } \overline{X}$$

La distribución de esas medias es la distribución muestral de la media. Este concepto es fundamental porque permite medir la variabilidad esperada de una media muestral y calcular probabilidades sobre posibles resultados de muestras.

3.1. Error de muestreo

Como una muestra es solo una parte de la población, no es esperable que su media sea exactamente igual a la media poblacional. La diferencia entre la media muestral y la media poblacional se denomina **error de muestreo**:

$$\text{Error de muestreo} = \overline{X} - \mu$$

Si $\overline{X}$ es mayor que μ, el error de muestreo es positivo. Si $\overline{X}$ es menor que μ, el error es negativo. Esto no necesariamente indica un error de procedimiento; es una consecuencia natural de trabajar con muestras.

Por ejemplo, en el caso del Foxtrot Inn, la media poblacional de habitaciones rentadas en junio fue:

$$\mu = \frac{\sum X}{N} = \frac{94}{30} = 3{,}13$$

Si tres muestras arrojan medias de 3,80; 3,40 y 1,80 habitaciones, sus errores de muestreo son:

Errores de muestreo en tres muestras:

- Muestra 1: media muestral 3,80; error de muestreo +0,67.
- Muestra 2: media muestral 3,40; error de muestreo +0,27.
- Muestra 3: media muestral 1,80; error de muestreo -1,33.

Si se analizaran muchísimas muestras, los errores positivos y negativos tenderían a compensarse. Por eso, la media muestral es un estimador sin sesgo de la media poblacional.

4. Propiedades de la distribución muestral de la media

La distribución muestral de la media posee tres propiedades esenciales. La primera es que la media de todas las medias muestrales es igual a la media poblacional:

$$\mu_{\overline{X}} = \mu$$

Esta relación significa que, si pudiéramos tomar todas las muestras posibles de un mismo tamaño y calcular sus medias, el promedio de esas medias coincidiría con la media real de la población.

La segunda propiedad es que la distribución de las medias muestrales tiene menor dispersión que la distribución original de la población. Las medias son más estables que las observaciones individuales porque cada media resume varios datos.

La tercera propiedad es que, bajo las condiciones del Teorema del Límite Central, la distribución muestral de la media tiende a adoptar forma normal. Esta propiedad es la base para calcular probabilidades usando la distribución normal estándar.

4.1. Ejemplo didáctico: Tartus Industries

Tartus Industries cuenta con siete empleados de producción. Los ingresos por hora son:

Datos de la población: Joe gana $7 por hora; Sam, $7; Sue, $8; Bob, $8; Jan, $7; Art, $8; y Ted, $9.

La media poblacional se calcula como:

$$\mu = \frac{\sum X}{N} = \frac{7 + 7 + 8 + 8 + 7 + 8 + 9}{7} = 7{,}71$$

Si se toman muestras de tamaño 2 sin reemplazo, el número de muestras posibles se calcula mediante combinaciones:

$$\binom{N}{n} = \frac{N!}{n!\,(N-n)!}$$

Aplicando la fórmula:

$$\binom{7}{2} = \frac{7!}{2!\,(7-2)!} = 21$$

Existen entonces 21 muestras posibles de tamaño 2. Al calcular la media de cada muestra, se obtiene la siguiente distribución muestral:

Distribución muestral resultante:

- Media muestral $7,00: aparece 3 veces; probabilidad 0,1429.
- Media muestral $7,50: aparece 9 veces; probabilidad 0,4285.
- Media muestral $8,00: aparece 6 veces; probabilidad 0,2857.

- Media muestral $8,50: aparece 3 veces; probabilidad 0,1429.
- Total: 21 medias muestrales; probabilidad acumulada 1,0000.

La suma de las 21 medias muestrales es 162. Por lo tanto, la media de la distribución muestral es:

$$\mu_{\overline{X}} = \frac{162}{21} = 7{,}71$$

El resultado confirma la propiedad fundamental:

$$\mu_{\overline{X}} = \mu = 7{,}71$$

Este ejemplo muestra que la media muestral puede variar de una muestra a otra, pero el promedio de todas las medias muestrales coincide con la media poblacional.

5. Error estándar de la media

El **error estándar de la media** mide la variabilidad de la distribución muestral de las medias. Es decir, indica cuánto se espera que varíen las medias muestrales alrededor de la media poblacional.

La fórmula es:

$$\sigma_{\overline{X}} = \frac{\sigma}{\sqrt{n}}$$

donde $\sigma_{\overline{X}}$ es el error estándar de la media, σ es la desviación estándar poblacional y n es el tamaño de la muestra.

Esta expresión muestra una relación central: a medida que aumenta el tamaño de la muestra, el error estándar disminuye. Esto ocurre porque el tamaño de la muestra se encuentra en el denominador dentro de una raíz cuadrada.

Por ejemplo, si la desviación estándar poblacional es $\sigma = 2{,}1$ y se toma una muestra de $n = 81$, entonces:

$$\sigma_{\overline{X}} = \frac{2{,}1}{\sqrt{81}} = \frac{2{,}1}{9} = 0{,}233$$

La interpretación es que las medias muestrales de tamaño 81 se dispersan alrededor de la media poblacional con una desviación estándar aproximada de 0,233.

Principio de precisión. Las muestras más grandes producen medias muestrales más estables. Sin embargo, la reducción del error no es lineal: para reducir el error estándar a la mitad, se necesita multiplicar por cuatro el tamaño de la muestra.

6. El Teorema del Límite Central

El **Teorema del Límite Central** establece que, si se seleccionan todas las muestras posibles de un tamaño determinado desde cualquier población, la distribución muestral de la media se aproxima a una distribución normal. Esta aproximación mejora a medida que aumenta el tamaño de la muestra.

En forma resumida:

$$\overline{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

Esto significa que la media muestral se comporta aproximadamente como una variable normal con media μ y varianza σ^2/n.

El TLC es central porque permite usar la distribución normal para calcular probabilidades de medias muestrales, incluso cuando la población original no tiene forma normal.

6.1. Condiciones de aplicación

El material base distingue tres situaciones importantes:

Condiciones de aplicación:

- Si la población es normal, la distribución de $\overline{X}$ será normal para cualquier tamaño de muestra.
- Si la población es simétrica, aunque no sea normal, la normalidad puede aparecer con muestras pequeñas, por ejemplo $n = 10$.
- Si la población es asimétrica o tiene colas gruesas, se requieren muestras más grandes, usualmente $n \geq 30$.

Una regla práctica frecuentemente utilizada establece que, cuando el tamaño de la muestra es al menos 30 ($n \geq 30$), la distribución muestral de la media puede aproximarse a una distribución normal. Sin embargo, este valor constituye una orientación práctica y no una condición suficiente universal. La calidad de la aproximación depende de las características

de la población original, especialmente de su asimetría y de la presencia de valores extremos, así como del cumplimiento de los supuestos del Teorema del Límite Central.

Por lo tanto, el valor $n = 30$ debe interpretarse como una referencia inicial y no como una garantía de normalidad. En poblaciones aproximadamente simétricas, muestras menores pueden resultar suficientes, mientras que en poblaciones muy asimétricas o con colas pesadas pueden requerirse muestras considerablemente mayores.

7. El TLC en acción: Spence Sprockets, Inc.

El ejemplo de Spence Sprockets muestra cómo el tamaño de la muestra modifica la forma de la distribución muestral. La empresa cuenta con 40 empleados cuyos tiempos de servicio siguen una distribución con sesgo positivo. La media poblacional del tiempo de servicio es:

$$\mu = 4{,}80 \text{ años}$$

Cuando se seleccionan 25 muestras de tamaño $n = 5$, la distribución de las medias comienza a alejarse del sesgo de la población original, pero todavía conserva irregularidades. En cambio, al seleccionar 25 muestras de tamaño $n = 20$, la distribución muestral adopta una forma mucho más parecida a una campana normal.

En el ejemplo, la media de las 25 muestras de tamaño 20 es aproximadamente:

$$\mu_{\overline{X}} = 4{,}676 \approx \mu$$

La enseñanza principal es que, cuanto mayor sea el tamaño de la muestra, más evidente se vuelve la convergencia hacia la normalidad y más estable resulta la media muestral.

8. Valor Z para medias muestrales

Cuando la distribución muestral de la media puede considerarse normal, se pueden calcular probabilidades mediante la estandarización. Para observaciones individuales, el valor Z compara un dato con la media usando la desviación estándar poblacional. Para medias muestrales, se reemplaza la desviación estándar por el error estándar.

La fórmula es:

$$Z = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

El denominador $\sigma/\sqrt{n}$ es el error estándar de la media. Por eso, el valor Z indica cuántos errores estándar se encuentra una media muestral por encima o por debajo de la media poblacional.

Si Z es positivo, la media muestral está por encima de la media poblacional. Si Z es negativo, está por debajo. Luego, el valor se interpreta con la tabla normal estándar.

8.1. Ejemplo: Cola, Inc.

Los registros indican que la cantidad de bebida de cola contenida en las botellas sigue una distribución normal con:

$$\mu = 31{,}2 \text{ onzas}$$

$$\sigma = 0{,}4 \text{ onzas}$$

Se selecciona una muestra de $n = 16$ botellas y se obtiene una media muestral:

$$\overline{X} = 31{,}38 \text{ onzas}$$

Primero se calcula el error estándar:

$$\sigma_{\overline{X}} = \frac{0{,}4}{\sqrt{16}} = \frac{0{,}4}{4} = 0{,}10$$

Luego se calcula el valor Z:

$$Z = \frac{31{,}38 - 31{,}20}{0{,}4/\sqrt{16}} = \frac{0{,}18}{0{,}10} = 1{,}80$$

Con la tabla normal estándar:

$$P(Z > 1{,}80) = 0{,}5000 - 0{,}4641 = 0{,}0359$$

La probabilidad de obtener una media muestral tan alta por azar es menor al 4%. La conclusión del ejemplo es que el proceso está llenando demasiado las botellas y se debería ajustar la línea de producción.

9. Ejemplos de aplicación con el TLC

Los siguientes ejemplos muestran cómo utilizar el error estándar y el valor Z para calcular probabilidades de medias muestrales.

9.1. Población normal

Una población normal tiene media $\mu = 60$ y desviación estándar $\sigma = 12$. Se selecciona una muestra de tamaño $n = 9$.

El error estándar es:

$$\sigma_{\overline{X}} = \frac{12}{\sqrt{9}} = 4$$

Para calcular $P(\overline{X} > 63)$:

$$Z = \frac{63 - 60}{4} = 0{,}75$$

Según la tabla normal:

$$P(\overline{X} > 63) = P(Z > 0{,}75) = 0{,}2266$$

Para calcular $P(\overline{X} < 56)$:

$$Z = \frac{56 - 60}{4} = -1{,}00$$

$$P(\overline{X} < 56) = P(Z < -1{,}00) = 0{,}1587$$

Entonces:

$$P(56 < \overline{X} < 63) = 1 - 0{,}2266 - 0{,}1587 = 0{,}6147$$

9.2. Baterías Mattel

La vida media de las baterías es $\mu = 35{,}0$ horas, con desviación estándar $\sigma = 5{,}5$ horas. Se toma una muestra de $n = 25$.

El error estándar es:

$$\sigma_{\overline{X}} = \frac{5{,}5}{\sqrt{25}} = 1{,}10$$

Para calcular $P(\overline{X} > 36)$:

$$Z = \frac{36 - 35}{1{,}10} = 0{,}91$$

$$P(\overline{X} > 36) = 0{,}1814$$

Para calcular $P(\overline{X} > 34{,}5)$:

$$Z = \frac{34{,}5 - 35}{1{,}10} = -0{,}45$$

$$P(\overline{X} > 34{,}5) = 0{,}6736$$

9.3. HRC Seguros de Salud

El deducible anual tiene media $\mu = 502$ dólares y desviación estándar $\sigma = 100$ dólares. Se selecciona una muestra de $n = 60$.

El error estándar es:

$$\sigma_{\overline{X}} = \frac{100}{\sqrt{60}} \approx 12{,}91$$

Para calcular $P(477 < \overline{X} < 527)$, los extremos se estandarizan aproximadamente como $Z = -1{,}94$ y $Z = 1{,}94$. Por lo tanto:

$$P(477 < \overline{X} < 527) \approx 0{,}9474$$

Para el intervalo $492 < \overline{X} < 512$, los valores Z son aproximadamente $-0{,}77$ y $0{,}77$:

$$P(492 < \overline{X} < 512) \approx 0{,}5588$$

Para $P(\overline{X} > 550)$:

$$Z = \frac{550 - 502}{12{,}91} \approx 3{,}72$$

$$P(\overline{X} > 550) \approx 0{,}0001$$

La probabilidad es extremadamente baja, por lo que una media muestral superior a 550 sería poco esperable si el proceso se mantuviera con media poblacional 502.

10. Lectura metodológica para auditoría de procesos

El valor del Teorema del Límite Central no está solo en una fórmula. Su importancia práctica es que permite transformar el comportamiento de muchas muestras posibles en una herramienta de decisión.

Cuando se audita un proceso, se observa una muestra y se calcula una media. Esa media puede diferir de la media poblacional esperada por azar. La pregunta estadística es si la diferencia observada es razonable o si es tan extrema que sugiere un cambio en el proceso.

El procedimiento básico es:

1. Identificar la media poblacional esperada μ.
2. Conocer o estimar la desviación estándar poblacional σ.
3. Seleccionar una muestra de tamaño n.
4. Calcular la media muestral $\overline{X}$.
5. Calcular el error estándar $\sigma_{\overline{X}} = \sigma/\sqrt{n}$.
6. Calcular el valor Z.
7. Interpretar la probabilidad obtenida en la tabla normal.

Si la probabilidad es muy baja, la media muestral observada puede ser una señal de que el proceso ya no se comporta como se esperaba.

11. Fórmulas esenciales

Fórmulas esenciales del capítulo:

- Intervalo sistemático: $k = \frac{N}{n}$. Sirve para seleccionar cada k-ésimo elemento de una población ordenada.
- Combinaciones: $\binom{N}{n} = \frac{N!}{n!(N-n)!}$. Sirve para contar cuántas muestras posibles de tamaño n pueden formarse desde una población de tamaño N.
- Media poblacional: $\mu = \frac{\sum X}{N}$. Resume el promedio de todos los valores de la población.
- Error de muestreo: $\overline{X} - \mu$. Mide la diferencia entre la media muestral y la media poblacional.
- Media de las medias muestrales: $\mu_{\overline{X}} = \mu$. Expresa que la distribución muestral está centrada en la media poblacional.
- Error estándar: $\sigma_{\overline{X}} = \frac{\sigma}{\sqrt{n}}$. Mide la dispersión de las medias muestrales.

- Valor Z para medias muestrales: $Z = \frac{\overline{X}-\mu}{\sigma/\sqrt{n}}$. Permite calcular probabilidades asociadas a medias de muestras.
- Regla práctica del TLC: $n \geq 30$. Se utiliza como referencia para considerar una muestra suficientemente grande.

12. Síntesis final

La distribución muestral de la media explica cómo se comportan las medias que se obtienen al repetir muchas veces el proceso de muestreo. Aunque cada muestra puede producir una media distinta, el promedio de todas las medias muestrales coincide con la media poblacional.

El error de muestreo es inevitable porque una muestra no es la población completa. El error estándar de la media permite medir la variabilidad esperada de las medias muestrales y muestra por qué las muestras grandes producen estimaciones más precisas.

El Teorema del Límite Central completa el puente hacia la inferencia: establece que, bajo condiciones apropiadas, la distribución muestral de la media se aproxima a la normal. Esta propiedad permite calcular probabilidades mediante el valor Z y fundamenta muchas decisiones estadísticas en control, auditoría y análisis de procesos.

En resumen, el recorrido conceptual es:

$$\text{Muestra} \rightarrow \overline{X} \rightarrow \text{distribución muestral} \rightarrow \sigma_{\overline{X}} \rightarrow Z \rightarrow \text{probabilidad}$$

Comprender este recorrido permite interpretar una media muestral no como un número aislado, sino como parte de un comportamiento probabilístico que hace posible la inferencia estadística.

Autor del material: Prof. Cristian Mut

Bibliografía

- Devore, J. L. (2009). *Probabilidad y estadística para ingeniería y ciencias* (7.ª ed.). Cengage Learning.
- Triola, M. F. (2018). *Estadística* (12.ª ed.). Pearson Educación.
- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probabilidad y estadística para ingeniería y ciencias* (9.ª ed.). Pearson Educación.